

选题	A	参赛编号	apmcm26203797
----	---	------	---------------

基于时滞识别与机理-数据融合的自来水厂水浊度预测及风险评估模型

摘要

自来水厂出厂水水质直接关系到供水安全，其变化过程受到原水指标、操作变量等多种因素的共同影响。针对题目给出的多源时序监测数据，本文围绕影响因素识别、水质动态预测以及运行策略优化等问题展开研究，构建兼具解释性与预测能力的数学模型，为水厂精细化运行管理提供决策依据。

针对问题一，首先通过

针对问题二，

针对问题三，

针对问题四，

关键词：水浊度预测；时滞识别；机理-数据融合；随机森林；XGBoost；GRU；水质风险评估

1 问题重述

自来水厂生产过程包括取水、混凝、沉淀、过滤、消毒和出厂输送等多个环节。原水浊度、原水 pH、原水流量、矾投加量、滤后水浊度、清水池水位和出厂水流量等变量共同影响最终出厂水浊度。由于混凝反应、过滤过程和清水池调蓄作用均具有时间延迟，当前出厂水质并不完全由当前原水状态决定，而是受过去若干时刻水质和工艺参数共同影响。

本文需要基于给定的多变量时间序列数据，完成以下四项任务：

- (1) 筛选影响出厂水浊度 NTU 的主要因素，解释各因素影响程度和作用方向，并预测 2026 年 2 月 1 日、2 月 10 日、2 月 20 日的水浊度；
- (2) 建立滤后水浊度 $FILT.NTU$ 的动态时滞模型，描述原水指标和操作变量对滤后水浊度的滞后影响，并估计不同变量的时滞参数；
- (3) 结合质量守恒思想和数据驱动方法，建立未来 1-12 小时出厂水浊度预测模型，并给出指定日期 7:00 至 19:00 的预测结果；
- (4) 以 $NTU \leq 1$ 为硬性约束，结合超标幅度和异常持续时间，建立水质风险评价体系，对 2026 年近三个月水质进行风险分级。
- (5) 在研究时间范围内，各输入变量对滤后水浊度（ NTU ）的时间滞后效应保持稳定。

2 问题分析

本题本质上是一个具有多变量耦合、非线性响应和时间滞后的水处理过程建模问题。若直接采用普通静态回归模型，容易忽略矾投加、原水浊度变化和清水池调蓄对出厂水浊度的滞后影响；若仅采用深度学习模型，则解释性不足，难以说明不同变量的影响方向和作用机制。因此，本文采用“数据预处理-滞后特征构造-机器学习解释-动态预测-风险评价”的整体建模路线。




图 1 水浊度预测与风险评价总体建模流程

3 模型假设

- 假设 1：经过缺失值处理和异常值标记后的监测数据能够反映水厂主要运行规律。
- 假设 2：原水水质和工艺操作变量对滤后水、出厂水浊度的影响存在有限时滞，且主要时滞范围不超过 24 小时。
- 假设 3：清水池调蓄作用可由清水池水位和出厂水流量构造的近似水力停留时间特征表征。

- 假设 4: 短时传感器噪声不会改变水处理过程中的主要动态关系。
- 假设 5: 以生活饮用水浊度限值 $NTU \leq 1$ 作为判断出厂水是否超标的统一标准。
- 假设 6:

4 符号说明

表 1 主要符号说明

符号	含义
t	时间序号
h	预测步长
y_t	t 时刻出厂水浊度 NTU
z_t	t 时刻滤后水浊度 $FILT.NTU$
$x_{i,t}$	第 i 个输入变量在 t 时刻的观测值
τ_i	第 i 个变量的最优时滞
HRT_t	t 时刻近似水力停留时间特征
E_t	超标幅度
D_t	连续异常持续时间
V_t	浊度波动指标
R_t	综合风险指数
$RMSE$	均方根误差
MAE	平均绝对误差
R^2	决定系数

5 数据预处理与质量审计

5.1 数据合并与时间重构

原始附件由多个按月份或按日期工作表记录的 Excel 文件构成，不同文件在日期格式、字段完整性和缺失情况上存在差异。为保证后续时间序列建模的可靠性，本文首先对所有原始表格进行统一读取、字段标准化和时间重构。数据合并后共得到 5460 条两小时观测记录，时间范围为 2025 年 1 月 1 日 07:00 至 2026 年 4 月 1 日 05:00，合并后时间戳重复数为 0，最终输出为包含 21 个题目字段的统一数据表。

由于 2025 年月度附件中的日期存在 Excel 日期格式与“日/月/年”文本混用的情况，且部分日期可能被软件按“月/日”格式显示，本文不直接采用原始日期列作为时间索引，而是依据文件月份、每日固定 12 行观测顺序重建运营日。考虑到每日记录顺序为 07:00、09:00、...、23:00、01:00、03:00、05:00，本文将 01:00、03:00 和 05:00 记录归入下一自然日，从而得到严格递增的标准时间戳。

5.2 字段统一与变量说明

根据题目附录给出的变量含义，本文将不同文件中的表头统一映射为标准字段，包括原水水位、原水流量、原水浊度、原水 pH、滤后水浊度、清水池水位、处理后水浊度、余氯、矾投加量、出厂水流量等变量。对于题目未注明单位的字段，本文不额外推断单位，仅保留原始量纲。主要字段及其建模用途如表 2 所示。

表 2 主要字段及建模用途

字段	中文含义	建模用途
R/W NTU	原水浊度	反映进水颗粒污染负荷，是影响滤后水和出厂水浊度的核心输入变量
R/W PH	原水 pH 值	影响混凝反应效果，可能对滤后水浊度产生非线性影响
R/W FLOW	原水流量	反映进水负荷，影响水力停留时间和处理效率
FILT. NTU	滤后水浊度	衡量混凝、沉淀和过滤效果，是问题二的预测目标
C/W WELL LEVEL NTU	清水池水位 处理后水浊度	用于构造近似水力停留时间特征 问题一、问题三和问题四的核心目标变量
ALUM	明矾/混凝剂投加量	工艺控制变量，对浊度变化具有滞后调节作用
T/W FLOW	出厂水流量	用于表征出厂输送负荷及水力停留状态

5.3 缺失值类型划分

原始数据中存在不同类型的缺失。若直接对所有缺失值采用同一种插补方法，可能导致预测目标泄露或引入错误信息。因此，本文将缺失值划分为三类：

- (1) **结构性缺失**：某字段在整个月份内全部为空，说明该月份未记录该变量，不宜进行简单插补；
- (2) **预测目标缺失**：2026 年 2 月处理后水浊度 NTU 为空，此类缺失是题目要求预测的目标，不能插补；
- (3) **普通漏测**：个别时间点由于仪器或人工记录原因造成的缺失，可根据时间序列连续性进行线性插值或前后向填充。

合并后的缺失统计显示，核心变量中 R/W FLOW 缺失率为 0.20%，R/W NTU 缺失率为 0.02%，FILT. NTU 无缺失，C/W WELL LEVEL 缺失率为 0.04%，T/W FLOW 缺失率为 0.29%。这些变量整体较完整，可作为后续主要建模变量。相比之下，R/W PH、PH、ALUM 等变量缺失率约为 30%，F/RIDE 缺失率为 75.68%，18ML LEVEL 与 18ML FLOW 缺失率均为 100%，因此不适合作为所有模型的稳定输入变量。2026 年 2 月 NTU 整月 336 个观测值均为空，其中题目要求预测的 2 月 1 日、2 月 10 日和 2 月 20 日对应 36 个观测值，本文保留为空并作为后续预测目标。

原始字段 T/W PUMP DUTY 记录运行泵组合（如 1&2、2&4 等），由于泵编号本身不具有数据意义，而运行泵数量更能反映系统运行负荷，因此将其转换为“运行泵数量”特征。

表 3 核心字段缺失情况摘要

字段	缺失数	缺失率	处理策略
R/W FLOW	11	0.20%	普通漏测，采用插值或前后向填充
R/W NTU	1	0.02%	普通漏测，采用插值或前后向填充
FILT. NTU	0	0.00%	直接用于问题二建模
C/W WELL LEVEL	2	0.04%	普通漏测，采用插值或前后向填充
NTU	341	6.25%	区分预测目标缺失与普通漏测
R/W PH	1644	30.11%	作为完整变量模型中的辅助变量
ALUM	1645	30.13%	作为完整变量模型中的辅助变量
F/RIDE	4132	75.68%	缺失严重，不作为稳定主变量
18ML LEVEL	5460	100.00%	剔除，不进入模型
18ML FLOW	5460	100.00%	剔除，不进入模型

5.4 异常值与离群点识别

为保证模型训练的稳健性，本文对异常数据进行两层识别。第一层为硬异常检测，即依据变量物理合理范围和数据格式识别明显错误值。例如，pH 理论上应位于 0 至 14 之间，浊度、流量和水位不应为负数；对于数值字段中出现的非数字字符，如“49+.9”、“3.82.”等，本文将其作为格式异常记录，并在数值型输出列中保存为空值。

第二层为统计离群点识别。考虑到水质数据具有明显的时间连续性，本文采用 Hampel/MAD 方法对连续数值变量进行局部离群点检测。对于变量序列 x_t ，在以 t 为中心的局部窗口内计算中位数 m_t 和中位数绝对偏差 MAD_t 。若满足

$$|x_t - m_t| > 5 \times 1.4826 \times MAD_t, \quad (1)$$

则将该点标记为统计离群点。本文选取中心窗口长度为 13 个观测点，约对应 24 小时局部时间范围。需要强调的是，统计离群点仅用于数据质量审计，不直接删除原始数值。对于高 NTU 观测值，若其可能反映真实水质风险事件，则在风险评价模型中保留。

审计结果显示，R/W CLR、C/W WELL LEVEL、RIVER LEVEL、T/W FLOW、R/W NTU、FILT. NTU 和 NTU 等字段均存在一定数量的局部离群点。其中，NTU 检测到 101 个统计离群点，说明出厂水浊度存在若干明显波动时段。这些波动点既可能来自传感器噪声，也可能对应真实水质异常，因此本文在建模阶段进行标记，在风险评价阶段保留。

表 4 部分字段统计离群点数量

字段	离群点数
R/W CLR	305
C/W WELL LEVEL	264
RIVER LEVEL	208
T/W FLOW	157
R/W NTU	152
R/W FLOW	150
FILT. NTU	114
NTU	101
CL2	9
F/RIDE	5

5.5 出厂水浊度超标初步统计

由于问题四要求以出厂水浊度 NTU 为核心指标进行风险评价，本文在数据预处理阶段对 $NTU > 1$ 的观测值进行初步统计。统计结果显示，在有效 NTU 观测中，共有 179 条观测超过 1，占有效观测的 3.50%；连续超标区间共 31 段，最大 NTU 为 11.9。最长连续超标区间出现在 2025 年 9 月 15 日 07:00 至 2025 年 9 月 19 日 21:00，共 56 个观测点，持续 112 小时，区间最大 NTU 为 9.23。

需要指出的是，出厂水浊度超标属于水质风险现象，不等同于数据错误。因此，本文不在预处理阶段删除超标观测，而是在问题四中结合超标幅度、持续时间和波动程度建立风险评价模型。

5.6 预处理结果小结

经过上述处理，本文得到时间顺序一致、字段格式统一、缺失类型明确、异常点经过标记的多变量时间序列数据集。后续问题一和问题三主要采用缺失率较低、连续性较好的变量进行预测建模；问题二在分析滤后水浊度时，将根据变量完整性分别构建完整变量模型和稳健变量模型；问题四则保留所有可能反映真实风险的高 NTU 观测值，用于构建水质风险评价体系。

完整缺失明细、硬异常记录、统计离群点代表记录和连续超标区间统计见附录。

6 问题一：主要影响因素筛选与出厂水浊度预测模型

6.1 候选影响因素选取

结合水处理工艺机理和数据字段，选取原水浊度、原水 pH、原水流量、滤后水浊度、矾投加量、清水池水位和出厂水流量等变量作为候选影响因素。

表 5 候选变量及物理含义

变量	中文含义	建模作用
$R/W\ NTU$	原水浊度	主要输入变量，反映进入处理系统的颗粒污染负荷
$R/W\ PH$	原水 pH	影响混凝剂作用效果，可能具有非线性影响
$R/W\ FLOW$	原水流量	影响处理负荷和水力停留状态
$FILT.NTU$	滤后水浊度	反映过滤前后处理效果，是出厂水浊度的重要中间变量
$ALUM$	矾投加量	工艺控制变量，对浊度变化具有滞后调节作用
$C/W\ WELL\ LEVEL$	清水池水位	与清水池调蓄和水力停留过程相关
$T/W\ FLOW$	出厂水流量	与出厂输送负荷和停留时间相关

6.2 相关性分析与滞后相关性分析

首先采用 Pearson 相关系数和 Spearman 相关系数分析各变量与出厂水浊度之间的线性和单调关系。对于变量 x_i 与目标变量 y ，Pearson 相关系数为

$$r_{x_i,y} = \frac{\sum_{t=1}^n (x_{i,t} - \bar{x}_i)(y_t - \bar{y})}{\sqrt{\sum_{t=1}^n (x_{i,t} - \bar{x}_i)^2} \sqrt{\sum_{t=1}^n (y_t - \bar{y})^2}}. \tag{2}$$

进一步地, 对不同滞后阶数下的变量与目标变量计算相关性, 以识别潜在时滞影响。

6.3 基于 XGBoost 的出厂水浊度预测模型

为刻画输入变量与出厂水浊度之间的非线性关系, 本文建立 XGBoost 回归模型。模型输入为当前变量及其滞后特征, 输出为出厂水浊度 y_t 。模型预测形式为

$$\hat{y}_t = F(X_t, X_{t-1}, \dots, X_{t-12}). \quad (3)$$

6.4 基于 SHAP 的变量重要性解释

为避免机器学习模型成为黑箱, 本文采用 SHAP 方法解释不同变量对模型输出的贡献。SHAP 值为正表示该变量在对应样本中推高预测浊度, SHAP 值为负表示该变量降低预测浊度。

6.5 模型性能与指定日期预测结果

表 6 不同模型对出厂水 NTU 的预测性能对比

模型	$RMSE$	MAE	R^2
多元线性回归			
随机森林			
XGBoost			
GRU			

表 7 2026 年 2 月指定日期出厂水 NTU 预测结果

日期	时间	预测值	真实值	绝对误差
2026-02-01				
2026-02-10				
2026-02-20				

7 问题二：滤后水浊度的时滞动态模型

7.1 滤后水浊度影响机制分析

滤后水浊度 $FILT.NTU$ 是衡量混凝、沉淀和过滤效果的重要指标。原水浊度反映进入处理系统的颗粒负荷, 原水 pH 会影响混凝剂效果, 矾投加量是调控混凝反应的关键变量, 原水流量则影响反应时间和过滤负荷。上述变量对滤后水浊度的影响并非即时发生, 而是存在不同程度的时间滞后。

7.2 动态时滞模型建立

设 z_t 表示 t 时刻滤后水浊度, $x_{i,t-\tau_i}$ 表示第 i 个输入变量在滞后 τ_i 后对滤后水浊度产生影响, 则动态模型可表示为

$$z_t = f(x_{1,t-\tau_1}, x_{2,t-\tau_2}, \dots, x_{m,t-\tau_m}) + \varepsilon_t. \quad (4)$$

其中, $\tau_i \in \{0, 1, \dots, 12\}$, 对应 0-24 小时滞后。

7.3 最优时滞参数识别

本文结合滞后相关性、网格搜索和模型特征重要性确定各变量的最优时滞。对于每个变量, 在候选滞后阶数集合中选择使模型预测误差最小或特征贡献最大的滞后阶数。

表 8 主要输入变量的最优时滞参数

输入变量	最优滞后阶数	滞后时间/h	作用方向
R/W NTU			
R/W PH			
$ALUM$			
$F/RIDE$			
R/W $FLOW$			

7.4 模型验证

表 9 $FILT.NTU$ 动态模型预测性能

模型	$RMSE$	MAE	R^2
ARX 基准模型			
滞后随机森林模型			
Lag-XGBoost 模型			

8 问题三：基于水力停留时间与 GRU 的出厂水浊度多步预测模型

由于 18ML LEVEL 和 18ML FLOW 在本数据集中完全缺失, 本文不将其纳入模型, 而采用 C/W WELL LEVEL 与 T/W FLOW 构造近似水力停留时间特征。清水池具有调蓄和混合作用, 当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用 L_t 表示清水池水位, 用 Q_t 表示出厂水流量, 则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (5)$$

其中 ϵ 为防止分母为零的极小常数。

8.1 水力停留时间特征构造

清水池具有调蓄和混合作用, 当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用 L_t 表示清水池水位, 用 Q_t 表示出厂水流量, 则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (6)$$

其中 ϵ 为防止分母为零的极小常数。

8.2 多步预测问题定义

由于采样间隔为 2 小时，未来 1–12 小时预测可转化为未来 1–6 步预测。设 $h = 1, 2, \dots, 6$ ，则多步预测目标为

$$\hat{y}_{t+h} = g(y_{t-k:t}, z_{t-k:t}, X_{t-k:t}, HRT_{t-k:t}), \quad (7)$$

其中 k 表示历史窗口长度。

8.3 GRU 模型结构

GRU 通过更新门和重置门刻画历史序列信息，其基本结构为

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r), \quad (8)$$

$$u_t = \sigma(W_u x_t + U_u h_{t-1} + b_u), \quad (9)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h), \quad (10)$$

$$h_t = (1 - u_t) \odot h_{t-1} + u_t \odot \tilde{h}_t. \quad (11)$$

8.4 多步预测性能评价

表 10 不同预测步长下模型预测性能

预测步长	对应时间	$RMSE$	MAE	R^2
1 step	2 h			
2 steps	4 h			
3 steps	6 h			
4 steps	8 h			
5 steps	10 h			
6 steps	12 h			

8.5 指定日期 7:00 至 19:00 预测结果

表 11 2026 年 2 月指定日期 7:00 至 19:00 出厂水 NTU 预测结果

日期	时间	2h 预测	4h 预测	6h 预测	12h 预测
2026-02-01	07:00				
2026-02-01	09:00				
2026-02-01	11:00				
2026-02-01	13:00				
2026-02-01	15:00				
2026-02-01	17:00				
2026-02-01	19:00				

8.6 输入变量敏感性分析

为分析原水水质突变和矾投加调整对未来出厂水浊度预测结果的影响，本文设计情景扰动实验。设原始输入为 X_t ，扰动后输入为 X'_t ，则相对敏感度定义为

$$S_i = \frac{\Delta \hat{y} / \hat{y}}{\Delta x_i / x_i}. \tag{12}$$

9 问题四：水质风险评价模型

9.1 风险评价指标构建

以出厂水浊度 y_t 为核心指标，根据生活饮用水浊度限值 $NTU \leq 1$ 定义超标幅度

$$E_t = \max(0, y_t - 1). \tag{13}$$

同时定义浊度波动指标

$$V_t = |y_t - y_{t-1}|. \tag{14}$$

设 D_t 表示连续异常持续时间，则综合风险指数为

$$R_t = \alpha E_t + \beta D_t + \gamma V_t, \tag{15}$$

其中 α, β, γ 为权重，满足 $\alpha + \beta + \gamma = 1$ 。

9.2 风险等级划分

表 12 水质风险等级划分标准

风险等级	判定依据	含义
安全	未超标且波动较小	水质稳定达标
低风险	接近阈值或短时轻微波动	需要关注
中风险	短时超标或波动明显	需要采取调控措施
高风险	持续超标或严重异常	需要立即干预

9.3 2026 年近三个月风险评价结果

表 13 2026 年 1-3 月各风险等级天数占比

风险等级	天数	占比
安全		
低风险		
中风险		
高风险		

表 14 2026 年 3 月每日风险分类结果

日期	日均 NTU	日最大 NTU	连续超标时长/h	风险等级
2026-03-01				
2026-03-02				
此处补充 3 月完整日期结果				

10 模型评价与敏感性分析

本节从预测精度、解释性、稳定性和实际应用价值四个方面评价模型。预测精度采用 $RMSE$ 、 MAE 和 R^2 衡量；解释性通过 SHAP 重要性、时滞参数和风险指标构成体现；稳定性通过不同月份、不同预测步长和输入扰动情景下的模型表现进行检验。

11 模型优缺点

11.1 模型优点

- (1) 充分考虑水处理过程的时间滞后特征，避免静态建模的局限；
- (2) 将 XGBoost、SHAP 与 GRU 结合，兼顾预测精度和可解释性；
- (3) 引入近似水力停留时间特征，使模型具有一定机理解释；
- (4) 风险评价同时考虑超标幅度、持续时间和波动程度，较单一阈值判断更合理。

11.2 模型不足

- (1) 清水池水力停留时间只能由水位和流量近似表征，可能与真实停留时间存在偏差；
- (2) 部分变量缺失率较高，可能影响完整变量模型的稳定性；
- (3) 对极端异常工况的预测能力依赖历史样本覆盖情况。

12 结论

本文围绕自来水厂水浊度预测与风险评估问题，构建了从数据预处理、影响因素筛选、时滞动态建模、多步预测到风险分级的完整建模框架。后续将在完成数据清洗和模型训练后，补充各问题的具体数值结果、预测表格和图形分析。

参考文献

- [1] 国家市场监督管理总局, 中国国家标准化管理委员会. 生活饮用水卫生标准: GB 5749-2022[S]. 北京: 中国标准出版社, 2022.
- [2] Qasim S R, Motley E M, Zhu G. Water Works Engineering: Planning, Design and Operation[M]. Upper Saddle River: Prentice Hall, 2000.
- [3] Box G E P, Jenkins G M, Reinsel G C, Ljung G M. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: Wiley, 2015.
- [4] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [5] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 2017, 30: 4765-4774.
- [7] Cho K, van Merriënboer B, Gulcehre C, Bahdanau D, Bougares F, Schwenk H, Bengio Y. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]. Proceedings of EMNLP, 2014: 1724-1734.
- [8] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [9] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M/OL]. 3rd ed. Melbourne: OTexts, 2021. <https://otexts.com/fpp3/>, 访问时间: 2026 年 6 月 12 日.
- [10] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge: MIT Press, 2016.