

|    |   |      |               |
|----|---|------|---------------|
| 选题 | A | 参赛编号 | apmcm26203797 |
|----|---|------|---------------|

# 基于时滞识别与机理-数据融合的自来水厂水浊度预测及风险评估模型

## 摘要

自来水厂出厂水水质直接关系到供水安全，其变化过程受到原水指标、操作变量等多种因素的共同影响。针对题目给出的多源时序监测数据，本文围绕影响因素识别、水质动态预测以及运行策略优化等问题展开研究，构建兼具解释性与预测能力的数学模型，为水厂精细化运行管理提供决策依据。

针对问题一，本文采用统计分析与机器学习相结合的方法识别影响出厂水浊度（NTU）的关键因素。通过双数据集交叉验证、相关性分析、特征重要性排序及 SHAP 解释分析，筛选出滤后水浊度（FILT.NTU）、河流水位（RIVER LEVEL）、原水流量（R/W FLOW）和出厂流量（T/W FLOW）等核心影响因素。进一步结合滞后相关性分析构建 Selected-One-Lag 特征集，并建立 Random Forest、XGBoost 和广义可加模型（GAM）进行预测。结果表明，Random Forest 模型表现最优（RMSE=0.2162,  $R^2=0.3921$ ）。模型解释结果显示，FILT.NTU 与出厂水浊度呈显著正相关关系，而混凝剂投加量具有一定负向调节作用。最终预测的 2026 年 2 月 1 日、2 月 10 日和 2 月 20 日出厂水浊度均低于 1 NTU，其中 2 月 10 日具有相对较高的浊度风险。

针对问题二，

针对问题三，

针对问题四，

关键词：

# 1 问题重述

自来水厂生产过程包括取水、混凝、沉淀、过滤、消毒和出厂输送等多个环节。原水浊度、原水 pH、原水流量、矾投加量、滤后水浊度、清水池水位和出厂水流量等变量共同影响最终出厂水浊度。由于混凝反应、过滤过程和清水池调蓄作用均具有时间延迟，当前出厂水质并不完全由当前原水状态决定，而是受过去若干时刻水质和工艺参数共同影响。

本文需要基于给定的多变量时间序列数据，完成以下四项任务：

- (1) 筛选影响出厂水浊度  $NTU$  的主要因素，解释各因素影响程度和作用方向，并建立主要影响因素之间的函数关系，并预测 2026 年 2 月 1 日、2 月 10 日、2 月 20 日的水浊度；
- (2) 建立滤后水浊度  $FILT.NTU$  的动态时滞模型，描述原水指标和操作变量对滤后水浊度的滞后影响，并估计不同变量的时滞参数；
- (3) 结合质量守恒思想和数据驱动方法，建立未来 1–12 小时出厂水浊度预测模型，并给出指定日期 7:00 至 19:00 的预测结果；
- (4) 以  $NTU \leq 1$  为硬性约束，结合超标幅度和异常持续时间，建立水质风险评价体系，对 2026 年近三个月水质进行风险分级。
- (5) 在研究时间范围内，各输入变量对滤后水浊度（ $NTU$ ）的时间滞后效应保持稳定。

# 2 问题分析

## 2.1 问题一的分析

首先对原始监测数据进行质量审计和缺失值处理，随后利用相关性分析、随机森林、XGBoost 及 SHAP 等方法识别影响出厂水浊度的关键因素。考虑供水处理过程存在时间延迟效应，进一步采用交叉相关分析构建时滞特征，最终建立 Random Forest、XGBoost 和 GAM 预测模型，实现出厂水浊度预测。

## 2.2 问题二的分析

## 2.3 问题三的分析

## 2.4 问题四的分析

# 3 模型假设

- 假设 1： 经过缺失值处理和异常值标记后的监测数据能够反映水厂主要运行规律。
- 假设 2： 原水水质和工艺操作变量对滤后水、出厂水浊度的影响存在有限时滞，且主要时滞范围不超过 24 小时。
- 假设 3： 清水池调蓄作用可由清水池水位和出厂水流量构造的近似水力停留时间特征表征。
- 假设 4： 短时传感器噪声不会改变水处理过程中的主要动态关系。

- 假设 5：以生活饮用水浊度限值  $NTU \leq 1$  作为判断出厂水是否超标的统一标准。
- 假设 6：假设在研究时间范围内，各影响因素与出厂水浊度之间存在稳定的时滞关系。

## 4 符号说明

表 1 主要符号说明

| 符号        | 含义                      |
|-----------|-------------------------|
| $t$       | 时间序号                    |
| $h$       | 预测步长                    |
| $y_t$     | $t$ 时刻出厂水浊度 $NTU$       |
| $z_t$     | $t$ 时刻滤后水浊度 $FILT.NTU$  |
| $x_{i,t}$ | 第 $i$ 个输入变量在 $t$ 时刻的观测值 |
| $\tau_i$  | 第 $i$ 个变量的最优时滞          |
| $HRT_t$   | $t$ 时刻近似水力停留时间特征        |
| $E_t$     | 超标幅度                    |
| $D_t$     | 连续异常持续时间                |
| $V_t$     | 浊度波动指标                  |
| $R_t$     | 综合风险指数                  |
| $RMSE$    | 均方根误差                   |
| $MAE$     | 平均绝对误差                  |
| $R^2$     | 决定系数                    |

## 5 数据预处理与质量审计

### 5.1 数据合并与时间重构

原始附件由多个按月份或按日期工作表记录的 Excel 文件构成，为保证后续时间序列分析与预测建模的可靠性，本文首先对所有原始表格进行统一读取与整合，最终得到包含 5460 条两小时观测记录的统一数据集。数据时间范围覆盖 2025 年 1 月 1 日 07:00 至 2026 年 4 月 1 日 05:00，共包含题目涉及的 21 个字段，合并后时间戳重复数为 0。

由于部分原始附件同时存在 Excel 日期格式与“日/月/年”文本格式混用的问题，本文依据文件所属月份、每日固定观测顺序以及监测时间信息重建标准时间轴。

由于原始记录跨越自然日边界，本文将 01:00、03:00 和 05:00 观测归入下一自然日，从而构建严格递增的时间序列。

### 5.2 变量预处理

#### 5.2.1 字段统一与数据整理

根据题目附录给出的变量定义，本文将不同来源文件中的表头统一映射为标准字段名称，包括原水流量 (R/W FLOW)、原水浊度 (R/W NTU)、原水 pH (R/W PH)、滤后水浊度 (FILT. NTU)、处理后水浊度 (NTU)、余氯 (CL2)、混凝剂投加量 (ALUM) 以及出厂流量 (T/W FLOW) 等变量。对于题目未明确给出物理单位的字段，本文不额外推断其量纲，仅保留原始数据形式。

### 5.2.2 泵组运行状态转换

原始字段 R/W PUMP DUTY 和 T/W PUMP DUTY 使用泵组编号组合表示设备运行状态，例如“1&3”、“2&4”等。由于泵编号本身不具有数值大小意义，而运行泵数量能够更直接反映系统负荷水平，因此本文提取字段中的泵号信息，并将其转换为对应的运行泵数量特征，用于后续分析与建模。

### 5.2.3 变量标准化

由于各监测指标具有不同的物理量纲和数值范围，例如浊度、流量、水位及药剂投加量等变量之间存在明显尺度差异，直接进行统计分析和特征比较可能导致结果受到量纲影响。为提高不同变量之间的可比性，本文对所有连续变量采用 Z-score 标准化处理。标准化后，各变量均被转换为均值为 0、标准差为 1 的无量纲变量，使相关性分析、特征重要性评估以及模型解释结果能够更加直观地反映各因素对出厂水浊度的影响程度。

## 5.3 缺失值分析

原始数据中部分变量存在不同程度缺失，且缺失模式具有明显差异。统计结果表明，R/W FLOW、R/W NTU、FILT. NTU、C/W WELL LEVEL 和 T/W FLOW 等核心运行变量缺失率均低于 1%，具有较好的连续性和完整性；而 ALUM、CL2、R/W PH 等工艺控制变量缺失率约为 30%，F/RIDE 缺失率达到 75.68%。18ML LEVEL 与 18ML FLOW 在整个观测期间均为空值，不具备分析价值，因此在后续建模中予以剔除。此外，2026 年 2 月 NTU 整月缺失，对应题目要求预测的目标数据，因此保留为空，不参与插补。

进一步分析发现，部分变量的缺失并非随机漏测，而是来源于若干月份未进行记录。例如 ALUM、CL2、R/W PH 和 T/W PUMP DUTY 等变量均存在连续月份整体缺失的现象。因此，简单删除缺失样本将导致样本规模显著下降，而直接删除缺失变量又可能损失重要工艺信息。

针对不同研究任务，本文采用差异化的缺失值处理策略。

在问题一关键影响因素筛选阶段，为避免插补方法对变量重要性排序产生额外影响，本文分别构建“删除缺失特征”（方案 A）和“删除缺失样本”（方案 B）两套数据集进行交叉验证，以检验筛选结果的稳健性。

而在后续分析过程中，为保留时间序列连续性并充分利用有效样本信息，本文对缺失数据采用插值填补策略。对于连续型变量，优先采用线性插值进行补全；对于泵组运行状态等离散型变量，则采用前后邻近观测值的众数进行填补。

考虑到监测数据具有较强时间连续性，且大多数关键变量缺失率较低，上述方法能够较好地保持变量的动态变化趋势，避免因删除样本导致的信息损失。对于存在大段连续缺失、缺乏可靠插补依据的变量，仅对局部缺失片段进行补全，其余缺失记录予以保留，以降低插补误差对后续分析结果的影响。

## 5.4 异常值检测

为评估数据质量并识别可能存在的异常观测，本文对连续数值变量进行异常值检测。考虑到水质监测数据具有明显的时间连续性和局部稳定性，采用基于中位数绝对偏差（Median Absolute Deviation, MAD）的 Hampel 方法进行局部离群点识别。

对于时间序列  $x_t$ ，在以  $t$  为中心的局部窗口内计算中位数  $m_t$  与中位数绝对偏差  $MAD_t$ 。若满足

$$|x_t - m_t| > 5 \times 1.4826 \times MAD_t,$$

则将该观测标记为统计离群点。本文采用长度为 13 个观测点的中心窗口，对应约 24 小时的局部时间范围。

检测结果表明，原水浊度、滤后水浊度、处理后水浊度以及流量等变量均存在一定数量的局部异常观测。这些异常点既可能来源于传感器噪声或记录误差，也可能反映真实的水质波动事件。考虑到题目后续需要分析水质风险及异常变化过程，本文仅对离群点进行标记而不删除原始观测值，以保留实际运行过程中的关键信息。

离群点检测的目的在于识别可能存在的数据异常和极端运行状态。考虑到这些观测可能反映真实水质波动事件，本文在数据审计阶段仅进行标记而不直接删除。

对于后续预测模型，为了降低极少数极端浊度峰值对模型训练的影响，对 NTU 相关变量额外进行了上限截断处理。

## 6 问题一：主要影响因素筛选与出厂水浊度预测模型

### 6.1 候选影响因素选取

由于原始数据中部分变量存在不同程度缺失，直接采用单一数据处理策略可能导致变量重要性结果受到样本规模或特征完整性的影响。为提高结论的稳健性，在选取影响因素阶段，本文分别构建两套分析数据集进行交叉验证。

方案 A 采用“删除缺失特征”的策略，即保留全部目标值有效样本，删除存在缺失记录的输入变量；方案 B 采用“删除缺失样本”的策略，即保留全部非空输入变量，但删除任一输入特征存在缺失的观测记录。两种方案分别代表“保留样本规模优先”和“保留变量信息优先”的两种建模思路。

在两种缺失值处理方案构建的数据集上，分别采用 Pearson 相关分析、Spearman 相关分析、Random Forest 特征重要性、XGBoost 特征重要性以及 RF/XGBoost 的 SHAP 解释分析，共六种评价方法对变量影响程度进行评估。随后统计各变量进入六种方法前三重要变量的次数，以衡量其重要性的稳定性和一致性。完整排序结果见附录 A，统计结果如表 2 所示。出现频次越高，表明该变量在不同数据处理策略和分析框架下均具有较强且稳定的影响力。

表 2 主要影响因素综合筛选结果

| 变量            | 出现次数 |
|---------------|------|
| FILT.NTU      | 8    |
| RIVER LEVEL   | 6    |
| R/W FLOW      | 4    |
| T/W FLOW      | 4    |
| CLR           | 3    |
| ALUM          | 2    |
| R/W NTU       | 2    |
| T/W PUMP DUTY | 1    |

除统计分析结果外，本文进一步结合供水工艺机理对变量进行补充筛选。

统计结果表明，FILT.NTU、RIVER LEVEL、R/W FLOW 和 T/W FLOW 等变量在不同分析框架下均表现出较高的重要性。与此同时，考虑到 CL2 和 F/RIDE 分别反映消毒工艺状态和混凝剂投加状态，虽然其统计重要性相对较弱，但具有明确的工程意义，因此将其纳入最终影响因素集合。

最终确定的问题一关键影响因素如表 3 所示。

表 3 问题一最终关键影响因素

|             |         |          |          |
|-------------|---------|----------|----------|
| FILT.NTU    | CLR     | R/W FLOW | T/W FLOW |
| RIVER LEVEL | R/W NTU | ALUM     | CL2      |

后续影响程度分析、作用方向分析及预测模型构建均基于上述变量展开。

6.2 影响程度与作用方向分析

为进一步解释各影响因素对出厂水浊度（NTU）的作用机制，本文结合相关性分析与 SHAP 解释模型，对关键变量的影响程度及作用方向进行研究。

由于方案 B（删除缺失样本）在关键变量识别过程中表现出更好的稳定性，并且对应的 Random Forest 模型取得了更优预测性能，因此后续影响程度分析与作用方向分析均以方案 B 作为代表进行展示。图 1 给出了方案 B 下 Pearson 相关系数与 Spearman 相关系数热力图。Pearson 相关系数主要反映变量间的线性关系，而 Spearman 相关系数能够反映变量间的单调关系。由图可见，FILT.NTU、RIVER LEVEL、R/W NTU 等变量与出厂水浊度均表现出较明显的正相关关系，其中 FILT.NTU 与 NTU 的相关性最为显著，表明滤后水浊度是影响最终出厂水质的重要前置指标。




图 1 方案 B 下 Pearson 与 Spearman 相关系数热力图




图 2 方案 B 下两种模型的 SHAP 解释结果

同时本文采用 SHAP 方法对随机森林模型和 XGBoost 模型进行解释, 结果如图 2a和图 2b所示。SHAP 结果表明, FILT.NTU 和 RIVER LEVEL 具有最大的平均贡献度, 是影响出厂水浊度的核心因素。其中, 当 FILT.NTU 取值较高时, 其对应 SHAP 值主要分布于正区间, 说明滤后水浊度升高将显著提高出厂水浊度预测值; 同样, 较高的 RIVER LEVEL 也倾向于产生正向贡献, 表明较高水位状态下系统更容易出现浊度升高现象。

T/W FLOW 和 R/W FLOW 的重要性排名同样较高, 说明进出厂流量变化会通过改变系统运行负荷和水力停留条件影响最终水质。对于 ALUM 变量, 高取值样本对应的 SHAP 值多数位于负区间, 表明适当增加混凝剂投加量有助于降低出厂水浊度, 这与实际水处理工艺机理一致。

综合相关性分析、特征重要性分析及 SHAP 解释结果, FILT.NTU、RIVER LEVEL、R/W FLOW 和 T/W FLOW 在多种评价方法下均保持较高的重要性, 是影响出厂水浊度变化的核心因素。SHAP 分析进一步表明, FILT.NTU、RIVER LEVEL 以及进出厂流量总体与 NTU 呈正向关系, 而 ALUM 表现出负向调节作用, 说明增加混凝剂投加量有助于降低出厂水浊度。上述结论与实际水处理工艺机理相符, 为后续建立预测模型提供了依据。

### 6.3 变量时滞效应分析

自来水处理过程并非瞬时完成。原水进入水厂后需要经历混凝、沉淀、过滤、清水池调蓄及输配等多个处理环节, 因此当前时刻的出厂水浊度不仅可能受到同期变量影响, 也可能受到若干小时前运行状态和水质条件的影响。

为识别各影响因素对出厂水浊度的时间滞后效应, 本文采用交叉相关分析 (Cross-Correlation Analysis) 研究变量历史值与当前 NTU 之间的关联关系。对于每个候选变量  $x$ , 计算其不同滞后阶数下与目标变量 NTU 的相关系数:

$$\rho(k) = \text{corr}(x_{t-k}, \text{NTU}_t), k = 0, 1, 2, \dots, 12.$$

其中,  $k$  表示滞后阶数,  $x_{t-k}$  表示变量在  $k$  个观测时刻之前的取值,  $\text{NTU}_t$  表示当前时刻的出厂水浊度。相关函数  $\text{corr}(\cdot)$  分别采用 Pearson 相关系数和 Spearman 相关系数计算, 以同时刻画线性关系和单调关系。

由于监测数据每 2 小时采集一次, 因此  $\text{lag}1$ 、 $\text{lag}6$  和  $\text{lag}12$  分别对应 2 小时、12 小时和 24 小时前的历史信息。

首先, 对各候选变量在  $\text{lag}0 \sim \text{lag}12$  范围内进行滞后相关性分析, 以观察不同变量对出厂水浊度的影响是否存在明显时延。若某变量在短时滞后下仍保持较高相关性, 则说明其影响能够在后续运行过程中持续传递; 若相关性随滞后时间迅速衰减, 则表明其作用主要集中于当前或邻近时刻。然而, 直接保留所有滞后特征会产生大量高度相关变量, 不仅增加模型复杂度, 也容易引入冗余信息。因此, 本文进一步结合滞后相关性结果、水处理工艺机理以及变量物理意义, 为每个变量预设若干具有工程意义的候选滞后阶数, 并仅在该候选集合内进行筛选。

随后, 仅利用训练集数据计算候选滞后特征与目标变量之间的 Spearman 相关系数, 并选择绝对相关系数最大的滞后项作为该变量的代表性时滞特征。通过这种 Selected-One-Lag 策略, 每个原始变量最终仅保留一个最具代表性的滞后特征, 从而在保留主要时间信息的同时避免过度特征扩张, 提高模型稳定性与可解释性。

最终确定的关键变量时滞特征如表 4 所示。

表 4 关键变量最终采用的滞后特征

| 变量          | 滞后阶数 | 实际时间 |
|-------------|------|------|
| FILT. NTU   | 1    | 2 h  |
| R/W FLOW    | 1    | 2 h  |
| T/W FLOW    | 1    | 2 h  |
| ALUM        | 1    | 2 h  |
| F/RIDE      | 6    | 12 h |
| CLR         | 0    | 0 h  |
| R/W NTU     | 0    | 0 h  |
| CL2         | 0    | 0 h  |
| RIVER LEVEL | 0    | 0 h  |

由表4可见，大多数关键变量的代表性滞后集中在 0–1 个时间步（0–2 小时）内，说明出厂水浊度主要受近期工况影响。其中，FILT.NTU、R/W FLOW、T/W FLOW 及 ALUM 均表现出短时滞后效应，表明这些变量的变化通常会在数小时内传递至出厂水水质。相比之下，CLR、R/W NTU、CL2 及 RIVER LEVEL 的代表性滞后均为 0，未观察到明显的时滞特征，其当前状态已能够有效表征对出厂水浊度的影响。值得注意的是，F/RIDE 的代表性滞后为 6 个时间步（12 小时），显著长于其他变量，表明其变化对出厂水浊度的影响可能需要经过较长处理链后才能体现出来。

基于上述分析，本文采用 Selected-One-Lag 策略，即每个变量仅保留一个代表性滞后项，从而在保留主要时序信息的同时避免引入大量高度相关的冗余特征。后续函数关系建模与预测分析均基于该特征集展开。

## 6.4 出厂水浊度预测模型

为提高预测结果的可靠性，本文首先对题目要求预测的 2026 年 2 月 1 日、2 月 10 日和 2 月 20 日附近运行状态进行检查。

结果表明，上述日期附近的原水浊度、滤后水浊度、流量及药剂投加等主要影响因素均处于历史正常波动范围内，未出现明显突变或持续异常现象，也未观测到高浊度冲击事件。因此，本文将这三个待预测日期视为常规运行工况下的预测样本，并基于历史正常运行数据建立预测模型。

在直接使用原始 NTU 数据训练模型时发现，历史样本中存在少量极端高浊度峰值。这类样本持续时间短、出现频率低，但由于其数值远高于正常运行区间，会在模型训练过程中占据较大的损失权重。对于以均方误差（MSE）为基础的学习算法而言，极端样本会驱动模型优先拟合少数异常事件，从而降低对大量常规工况样本的拟合能力，导致整体预测稳定性下降。然而，本题要求预测的三个目标日期均处于正常运行状态附近，因此本文更关注模型在常规运行区间内的预测精度，而非对极端异常事件的精确拟合。

为降低极端异常样本对模型训练的干扰，本文对 NTU 相关变量采用上限截断处理：

$$NTU^* = \min(NTU, 2).$$

即当 NTU 大于 2 时统一映射为 2，其余样本保持不变。

需要说明的是，该处理并非否定高浊度事件的重要性，而是为了防止模型过度拟合少量异常峰值，从而提高对常规运行状态下出厂水浊度的预测能力。同时，由于我国生活饮用水卫生标准要求出厂水浊度不超过 1 NTU，因此将截断阈值设为 2 并不会影响模型对于是否满足国标要求的判断。

为验证截断处理的有效性，本文分别在原始数据和截断数据上训练相同模型，并采用平均绝对误差（MAE）、均方根误差（RMSE）以及决定系数（ $R^2$ ）作为评价指标并



比较其预测性能，结果如表 5 所示。

表 5 截断处理前后模型性能比较

| 数据处理 | 模型            | MAE    | RMSE   | $R^2$   | MAPE(%) |
|------|---------------|--------|--------|---------|---------|
| 未截断  | Random Forest | 0.1755 | 0.2688 | 0.0756  | 51.66   |
|      | XGBoost       | 0.1933 | 0.3395 | -0.4739 | 50.57   |
|      | GAM           | 0.2044 | 0.3176 | -0.2903 | 53.78   |
| 截断后  | Random Forest | 0.1629 | 0.2162 | 0.3921  | 48.74   |
|      | XGBoost       | 0.1602 | 0.2242 | 0.3466  | 45.40   |
|      | GAM           | 0.1814 | 0.2245 | 0.3445  | 51.89   |

从表 5 可以看出，对目标变量进行截断处理后，三种模型的预测性能均得到明显改善。以 Random Forest 为例，RMSE 由 0.2688 降低至 0.2162， $R^2$  由 0.0756 提升至 0.3921；XGBoost 和 GAM 也表现出类似趋势。因此，除特别说明外，问题一中的相关性分析、影响方向分析、时滞分析以及预测模型构建均基于截断后的数据集进行。

根据前文影响因素筛选与时滞分析结果，最终选取 9 个关键变量构建预测模型，并保留各变量对应的代表性滞后特征（见表 4）。

记由表 4 所示 Selected-One-Lag 特征构成的输入变量集合为

$$X_t = \left\{ \begin{array}{lll} FILT.NTU_{t-1} & CLR_t & R/W FLOW_{t-1} \\ T/W FLOW_{t-1} & RIVER LEVEL_t & R/W NTU_t \\ CL2_t & ALUM_{t-1} & F/RIDE_{t-6} \end{array} \right\}.$$

则出厂水浊度预测问题可表示为

$$NTU_t = f(X_t).$$

由于各变量与出厂水浊度之间存在明显非线性关系，本文分别采用 Random Forest、XGBoost 以及 Generalized Additive Model (GAM) 对未知函数  $f(\cdot)$  进行逼近。

需要指出的是，Random Forest 和 XGBoost 虽然具有较强的非线性拟合能力，但其预测过程依赖于大量决策树结构与集成学习机制，难以直接给出输入变量与出厂水浊度之间的显式函数关系。因此，这两类模型更适用于预测性能评估，而不适用于解释变量的作用机理。

相比之下，GAM 将响应变量表示为多个平滑函数之和，在保持较好预测能力的同时，能够直接刻画各影响因素与出厂水浊度之间的非线性函数关系。其基本形式可表示为

$$NTU_t = \beta_0 + \sum_{i=1}^p f_i(x_i) + \varepsilon,$$

其中， $f_i(\cdot)$  表示由数据学习得到的平滑函数，反映第  $i$  个影响因素对出厂水浊度的边际贡献； $\beta_0$  为常数项； $\varepsilon$  为随机误差项。

在前述 Selected-One-Lag 特征基础上，本文构建 GAM 模型，并利用其平滑效应曲线分析各关键变量与出厂水浊度之间的函数关系。图 3 给出了主要变量对应的平滑效应曲线。其中横轴表示标准化后的变量取值，纵轴表示该变量对预测出厂水浊度的边际影响。

GAM Smooth Effect Curves for Selected-one-lag Features




图 3 关键变量对出厂水浊度的 GAM 平滑效应曲线

从图 3可以看出，不同变量对出厂水浊度的影响具有明显的非线性特征。其中，FILT.NTU 的平滑效应曲线整体呈显著上升趋势，并在较高取值区间出现明显加速增长，说明滤后水浊度是影响出厂水浊度最重要的因素之一。当滤后浊度超过一定水平后，其对出厂水浊度的放大效应显著增强，该现象反映出滤后水浊度与出厂水浊度之间存在非线性传递关系。

R/W FLOW 与 ALUM 的平滑效应曲线则表现出相似的变化规律。随着变量取值增加，其对预测出厂水浊度的边际影响逐渐增强，但在较高取值区间曲线逐渐趋于平缓，呈现出明显的边际效应递减特征。对于 R/W FLOW 而言，这表明原水流量增加会提高系统运行负荷，从而增加出厂水浊度升高的可能性；而对于 ALUM 而言，虽然增加混凝剂投加量有助于改善水质，但当投加量达到一定水平后，继续增加药剂所带来的改善效果逐渐减弱。

相比之下，T/W FLOW 的平滑效应曲线表现出更为明显的非单调特征。在较低至中等取值区间内，出厂流量增加会提高预测浊度，但当流量继续增大后，其边际影响逐渐减弱并出现下降趋势。这说明出厂流量与出厂水浊度之间并非简单的线性关系，而可能受到系统调蓄能力、运行调度策略以及其他工艺条件共同影响。

RIVER LEVEL、R/W NTU 和 CL2 的平滑效应曲线均呈现出一定程度的波动特征，表明这些变量与出厂水浊度之间存在较复杂的非线性关系。其中，RIVER LEVEL 在高取值区间整体表现出正向影响趋势，说明河流水文条件变化可能通过影响原水质量间接作用于出厂水浊度；R/W NTU 曲线则反映出原水浊度经过混凝、沉淀和过滤等处理环节后，其影响并不会简单传递至出厂端，而是受到多重工艺过程共同调节；CL2 的平滑效应曲线整体呈现非线性变化特征，在中等取值区间表现出一定的负向影响，说明

适当提高余氯水平有助于降低预测浊度。而在较高取值区间，曲线出现一定程度回升，表明余氯与出厂水浊度之间的关系并非简单线性关系。

此外，F/RIDE 对应的平滑效应曲线整体接近水平，仅表现出较弱的波动变化，说明该变量对出厂水浊度的直接影响相对有限，其在模型中主要起辅助解释作用。

综合各变量的平滑效应曲线可以发现，出厂水浊度与主要影响因素之间的关系并不完全服从简单线性规律。部分关键变量（如 FILT.NTU、T/W FLOW、RIVER LEVEL 和 R/W NTU）表现出明显的非线性特征，而 R/W FLOW、ALUM 等变量则呈现边际效应递减现象，F/RIDE 则近似表现为线性关系。总体而言，出厂水浊度的形成过程受到多种不同作用模式共同影响，体现出较强的系统复杂性。

## 6.5 模型性能评价与预测结果

### 6.5.1 模型性能评价

为评估不同模型在出厂水浊度预测中的表现，本文对 Random Forest、XGBoost 和 GAM 三种模型进行测试集验证。模型测试集性能结果如表 6 所示。

表 6 不同预测模型性能比较

| 模型            | MAE    | RMSE   | $R^2$  | MAPE(%) |
|---------------|--------|--------|--------|---------|
| Random Forest | 0.1629 | 0.2162 | 0.3921 | 48.74   |
| XGBoost       | 0.1602 | 0.2242 | 0.3466 | 45.40   |
| GAM           | 0.1814 | 0.2245 | 0.3445 | 51.89   |

从表 6 可以看出，三种模型均能够较好地捕捉出厂水浊度的变化规律。其中，XGBoost 在 MAE 指标上略优于其他模型，表明其平均预测误差最小；然而 Random Forest 在 RMSE 和  $R^2$  指标上均取得最佳结果，说明其对于整体样本的拟合能力更强，同时对较大预测误差具有更好的控制能力。

相比之下，GAM 的预测性能略低于两种树模型，但其 RMSE 和  $R^2$  与 XGBoost 接近，表明关键影响因素与出厂水浊度之间确实存在较明显的非线性关系。由于 Random Forest 同时具有最低 RMSE 和最高  $R^2$ ，因此本文将其选定为问题一的最终预测模型，并基于该模型完成指定日期的浊度预测。

### 6.5.2 指定日期预测结果

利用训练完成的 Random Forest 模型，对题目要求的 2026 年 2 月 1 日、2 月 10 日和 2 月 20 日进行预测。由于每个运行日包含多个监测时刻，为反映当日整体运行状态，本文统计各预测时刻的平均值、最小值、最大值及标准差，结果如表 7 所示。

表 7 指定日期出厂水浊度预测结果

| 日期         | 平均值    | 最小值    | 最大值    | 标准差    |
|------------|--------|--------|--------|--------|
| 2026-02-01 | 0.3041 | 0.2508 | 0.3627 | 0.0381 |
| 2026-02-10 | 0.5055 | 0.3576 | 0.6105 | 0.0766 |
| 2026-02-20 | 0.3066 | 0.2645 | 0.3936 | 0.0401 |

从预测结果可以看出，三个目标日期的预测浊度均低于我国生活饮用水卫生标准规定的浊度限值（ $\text{NTU} \leq 1$ ），表明在正常运行条件下，水厂出厂水质整体处于安全范围内，不存在明显超标风险。

进一步比较三个日期可以发现，2026 年 2 月 10 日的预测浊度显著高于 2 月 1 日和 2 月 20 日，其平均预测值达到 0.5055，而另外两个日期均维持在 0.31 左右。这说明在相同工艺条件下，2 月 10 日对应的原水环境和运行状态组合更容易导致出厂水浊度升高。

结合前文影响因素分析结果可知，FILT.NTU、RIVER LEVEL、R/W FLOW 和 T/W FLOW 是影响出厂水浊度变化的关键变量。因此，2 月 10 日预测值偏高可能反映了该时段滤后水浊度、河流水位或系统运行负荷处于相对不利状态，从而共同推动出厂水浊度上升。

总体而言，所建立的 Random Forest 模型能够较好地刻画出厂水浊度与关键运行变量之间的复杂非线性关系，并为指定日期的水质预测提供可靠依据。预测结果表明，研究期间水厂整体运行状态稳定，出厂水浊度满足饮用水安全要求。

## 7 问题二：滤后水浊度的时滞动态模型

### 7.1 滤后水浊度影响机制分析

滤后水浊度  $FILT.NTU$  是衡量混凝、沉淀和过滤效果的重要指标。原水浊度反映进入处理系统的颗粒负荷，原水 pH 会影响混凝剂效果，矾投加量是调控混凝反应的关键变量，原水流量则影响反应时间和过滤负荷。上述变量对滤后水浊度的影响并非即时发生，而是存在不同程度的时间滞后。

## 8 问题三：基于水力停留时间与 GRU 的出厂水浊度多步预测模型

由于 18ML LEVEL 和 18ML FLOW 在本数据集中完全缺失，本文不将其纳入模型，而采用 C/W WELL LEVEL 与 T/W FLOW 构造近似水力停留时间特征。清水池具有调蓄和混合作用，当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用  $L_t$  表示清水池水位，用  $Q_t$  表示出厂水流量，则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (1)$$

其中  $\epsilon$  为防止分母为零的极小常数。

### 8.1 水力停留时间特征构造

清水池具有调蓄和混合作用，当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用  $L_t$  表示清水池水位，用  $Q_t$  表示出厂水流量，则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (2)$$

其中  $\epsilon$  为防止分母为零的极小常数。

## 8.2 多步预测问题定义

由于采样间隔为 2 小时，未来 1-12 小时预测可转化为未来 1-6 步预测。设  $h = 1, 2, \dots, 6$ ，则多步预测目标为

$$\hat{y}_{t+h} = g(y_{t-k:t}, z_{t-k:t}, X_{t-k:t}, HRT_{t-k:t}), \quad (3)$$

其中  $k$  表示历史窗口长度。

## 8.3 GRU 模型结构

GRU 通过更新门和重置门刻画历史序列信息，其基本结构为

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r), \quad (4)$$

$$u_t = \sigma(W_u x_t + U_u h_{t-1} + b_u), \quad (5)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h), \quad (6)$$

$$h_t = (1 - u_t) \odot h_{t-1} + u_t \odot \tilde{h}_t. \quad (7)$$

## 8.4 多步预测性能评价

表 8 不同预测步长下模型预测性能

| 预测步长    | 对应时间 | $RMSE$ | $MAE$ | $R^2$ |
|---------|------|--------|-------|-------|
| 1 step  | 2 h  |        |       |       |
| 2 steps | 4 h  |        |       |       |
| 3 steps | 6 h  |        |       |       |
| 4 steps | 8 h  |        |       |       |
| 5 steps | 10 h |        |       |       |
| 6 steps | 12 h |        |       |       |

## 8.5 指定日期 7:00 至 19:00 预测结果

表 9 2026 年 2 月指定日期 7:00 至 19:00 出厂水 NTU 预测结果

| 日期         | 时间    | 2h 预测 | 4h 预测 | 6h 预测 | 12h 预测 |
|------------|-------|-------|-------|-------|--------|
| 2026-02-01 | 07:00 |       |       |       |        |
| 2026-02-01 | 09:00 |       |       |       |        |
| 2026-02-01 | 11:00 |       |       |       |        |
| 2026-02-01 | 13:00 |       |       |       |        |
| 2026-02-01 | 15:00 |       |       |       |        |
| 2026-02-01 | 17:00 |       |       |       |        |
| 2026-02-01 | 19:00 |       |       |       |        |

8.6 输入变量敏感性分析

为分析原水水质突变和矾投加调整对未来出厂水浊度预测结果的影响，本文设计情景扰动实验。设原始输入为  $X_t$ ，扰动后输入为  $X'_t$ ，则相对敏感度定义为

$$S_i = \frac{\Delta \hat{y} / \hat{y}}{\Delta x_i / x_i}. \tag{8}$$

9 问题四：水质风险评价模型

9.1 风险评价指标构建

以出厂水浊度  $y_t$  为核心指标，根据生活饮用水浊度限值  $NTU \leq 1$  定义超标幅度

$$E_t = \max(0, y_t - 1). \tag{9}$$

同时定义浊度波动指标

$$V_t = |y_t - y_{t-1}|. \tag{10}$$

设  $D_t$  表示连续异常持续时间，则综合风险指数为

$$R_t = \alpha E_t + \beta D_t + \gamma V_t, \tag{11}$$

其中  $\alpha, \beta, \gamma$  为权重，满足  $\alpha + \beta + \gamma = 1$ 。

9.2 风险等级划分

表 10 水质风险等级划分标准

| 风险等级 | 判定依据        | 含义       |
|------|-------------|----------|
| 安全   | 未超标且波动较小    | 水质稳定达标   |
| 低风险  | 接近阈值或短时轻微波动 | 需要关注     |
| 中风险  | 短时超标或波动明显   | 需要采取调控措施 |
| 高风险  | 持续超标或严重异常   | 需要立即干预   |

9.3 2026 年近三个月风险评价结果

表 11 2026 年 1-3 月各风险等级天数占比

| 风险等级 | 天数 | 占比 |
|------|----|----|
| 安全   |    |    |
| 低风险  |    |    |
| 中风险  |    |    |
| 高风险  |    |    |

表 12 2026 年 3 月每日风险分类结果

| 日期             | 日均 NTU | 日最大 NTU | 连续超标时长/h | 风险等级 |
|----------------|--------|---------|----------|------|
| 2026-03-01     |        |         |          |      |
| 2026-03-02     |        |         |          |      |
| 此处补充 3 月完整日期结果 |        |         |          |      |

## 10 模型评价与敏感性分析

本节从预测精度、解释性、稳定性和实际应用价值四个方面评价模型。预测精度采用  $RMSE$ 、 $MAE$  和  $R^2$  衡量；解释性通过 SHAP 重要性、时滞参数和风险指标构成体现；稳定性通过不同月份、不同预测步长和输入扰动情景下的模型表现进行检验。

## 11 模型优缺点

### 11.1 模型优点

- (1) 充分考虑水处理过程的时间滞后特征，避免静态建模的局限；
- (2) 将 XGBoost、SHAP 与 GRU 结合，兼顾预测精度和可解释性；
- (3) 引入近似水力停留时间特征，使模型具有一定机理解释；
- (4) 风险评价同时考虑超标幅度、持续时间和波动程度，较单一阈值判断更合理。

### 11.2 模型不足

- (1) 清水池水力停留时间只能由水位和流量近似表征，可能与真实停留时间存在偏差；
- (2) 部分变量缺失率较高，可能影响完整变量模型的稳定性；
- (3) 对极端异常工况的预测能力依赖历史样本覆盖情况。

## 12 结论

本文围绕自来水厂水浊度预测与风险评估问题，构建了从数据预处理、影响因素筛选、时滞动态建模、多步预测到风险分级的完整建模框架。后续将在完成数据清洗和模型训练后，补充各问题的具体数值结果、预测表格和图形分析。

## 参考文献

- [1] 国家市场监督管理总局, 中国国家标准化管理委员会. 生活饮用水卫生标准: GB 5749-2022[S]. 北京: 中国标准出版社, 2022.
- [2] Qasim S R, Motley E M, Zhu G. Water Works Engineering: Planning, Design and Operation[M]. Upper Saddle River: Prentice Hall, 2000.
- [3] Box G E P, Jenkins G M, Reinsel G C, Ljung G M. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: Wiley, 2015.
- [4] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [5] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 2017, 30: 4765-4774.
- [7] Cho K, van Merriënboer B, Gulcehre C, Bahdanau D, Bougares F, Schwenk H, Bengio Y. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]. Proceedings of EMNLP, 2014: 1724-1734.
- [8] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [9] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M/OL]. 3rd ed. Melbourne: OTexts, 2021. <https://otexts.com/fpp3/>, 访问时间: 2026 年 6 月 12 日.
- [10] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge: MIT Press, 2016.



## 13 附录

表 13 不同缺失值处理方案下各方法的重要变量排序结果

| 方案 | 最佳模型          | 最佳 RMSE | RF 重<br>要性前<br>三                               | XGB<br>重要性<br>前三                              | RF<br>SHAP<br>前三                                | XGB<br>SHAP<br>前三                               | Pearson<br>前三                                  | Spearman<br>前三                               |
|----|---------------|---------|------------------------------------------------|-----------------------------------------------|-------------------------------------------------|-------------------------------------------------|------------------------------------------------|----------------------------------------------|
| A  | XGBoost       | 0.3864  | FILT.<br>NTU,<br>CLR,<br>RIVER<br>LEVEL        | CLR,<br>FILT.<br>NTU,<br>R/W<br>FLOW          | FILT.<br>NTU,<br>T/W<br>FLOW,<br>RIVER<br>LEVEL | FILT.<br>NTU,<br>T/W<br>FLOW,<br>RIVER<br>LEVEL | FILT.<br>NTU,<br>CLR,<br>R/W<br>FLOW           | R/W<br>FLOW,<br>T/W<br>FLOW,<br>FILT.<br>NTU |
| B  | Random Forest | 0.0921  | FILT.<br>NTU,<br>RIVER<br>LEVEL,<br>R/W<br>NTU | FILT.<br>NTU,<br>T/W<br>PUMP<br>DUTY,<br>ALUM | RIVER<br>LEVEL,<br>FILT.<br>NTU,<br>T/W<br>FLOW | FILT.<br>NTU,<br>RIVER<br>LEVEL,<br>ALUM        | FILT.<br>NTU,<br>RIVER<br>LEVEL,<br>R/W<br>NTU | RIVER<br>LEVEL,<br>ALUM,<br>R/W<br>CLR       |