

选题	A	参赛编号	apmcm26203797
----	---	------	---------------

基于时滞识别与机理-数据融合的自来水厂水浊度预测及风险评估模型

摘要

自来水厂出厂水水质直接关系到供水安全，其变化过程受到原水指标、操作变量等多种因素的共同影响。针对题目给出的多源时序监测数据，本文围绕影响因素识别、水质动态预测以及运行策略优化等问题展开研究，构建兼具解释性与预测能力的数学模型，为水厂精细化运行管理提供决策依据。

针对问题一，首先通过数据集交叉验证和多方法综合评估筛选出影响出厂水浊度的关键因素。

针对问题二，

针对问题三，

针对问题四，

关键词：水浊度预测；时滞识别；机理-数据融合；随机森林；XGBoost；GRU；水质风险评估

1 问题重述

自来水厂生产过程包括取水、混凝、沉淀、过滤、消毒和出厂输送等多个环节。原水浊度、原水 pH、原水流量、矾投加量、滤后水浊度、清水池水位和出厂水流量等变量共同影响最终出厂水浊度。由于混凝反应、过滤过程和清水池调蓄作用均具有时间延迟，当前出厂水质并不完全由当前原水状态决定，而是受过去若干时刻水质和工艺参数共同影响。

本文需要基于给定的多变量时间序列数据，完成以下四项任务：

- (1) 筛选影响出厂水浊度 NTU 的主要因素，解释各因素影响程度和作用方向，并预测 2026 年 2 月 1 日、2 月 10 日、2 月 20 日的水浊度；
- (2) 建立滤后水浊度 $FILT.NTU$ 的动态时滞模型，描述原水指标和操作变量对滤后水浊度的滞后影响，并估计不同变量的时滞参数；
- (3) 结合质量守恒思想和数据驱动方法，建立未来 1-12 小时出厂水浊度预测模型，并给出指定日期 7:00 至 19:00 的预测结果；
- (4) 以 $NTU \leq 1$ 为硬性约束，结合超标幅度和异常持续时间，建立水质风险评价体系，对 2026 年近三个月水质进行风险分级。
- (5) 在研究时间范围内，各输入变量对滤后水浊度（ NTU ）的时间滞后效应保持稳定。

2 问题分析

本题本质上是一个具有多变量耦合、非线性响应和时间滞后的水处理过程建模问题。若直接采用普通静态回归模型，容易忽略矾投加、原水浊度变化和清水池调蓄对出厂水浊度的滞后影响；若仅采用深度学习模型，则解释性不足，难以说明不同变量的影响方向和作用机制。因此，本文采用“数据预处理-滞后特征构造-机器学习解释-动态预测-风险评价”的整体建模路线。




图 1 水浊度预测与风险评价总体建模流程

3 模型假设

- 假设 1：经过缺失值处理和异常值标记后的监测数据能够反映水厂主要运行规律。
- 假设 2：原水水质和工艺操作变量对滤后水、出厂水浊度的影响存在有限时滞，且主要时滞范围不超过 24 小时。
- 假设 3：清水池调蓄作用可由清水池水位和出厂水流量构造的近似水力停留时间特征表征。

- 假设 4： 短时传感器噪声不会改变水处理过程中的主要动态关系。
- 假设 5： 以生活饮用水浊度限值 $NTU \leq 1$ 作为判断出厂水是否超标的统一标准。
- 假设 6： 假设在研究时间范围内，各影响因素与出厂水浊度之间存在稳定的时滞关系。

4 符号说明

表 1 主要符号说明

符号	含义
t	时间序号
h	预测步长
y_t	t 时刻出厂水浊度 NTU
z_t	t 时刻滤后水浊度 $FILT.NTU$
$x_{i,t}$	第 i 个输入变量在 t 时刻的观测值
τ_i	第 i 个变量的最优时滞
HRT_t	t 时刻近似水力停留时间特征
E_t	超标幅度
D_t	连续异常持续时间
V_t	浊度波动指标
R_t	综合风险指数
$RMSE$	均方根误差
MAE	平均绝对误差
R^2	决定系数

5 数据预处理与质量审计

5.1 数据合并与时间重构

原始附件由多个按月份或按日期工作表记录的 Excel 文件构成，为保证后续时间序列分析与预测建模的可靠性，本文首先对所有原始表格进行统一读取与整合，最终得到包含 5460 条两小时观测记录的统一数据集。数据时间范围覆盖 2025 年 1 月 1 日 07:00 至 2026 年 4 月 1 日 05:00，共包含题目涉及的 21 个字段，合并后时间戳重复数为 0。

由于部分原始附件同时存在 Excel 日期格式与“日/月/年”文本格式混用的问题，本文依据文件所属月份、每日固定观测顺序以及监测时间信息重建标准时间轴。

由于原始记录跨越自然日边界，本文将 01:00、03:00 和 05:00 观测归入下一自然日，从而构建严格递增的时间序列。

5.2 变量标准化

根据题目附录给出的变量定义，本文将不同来源文件中的表头统一映射为标准字段名称，包括原水流量、原水浊度、原水 pH、滤后水浊度、处理后水浊度、余氯、混凝剂投加量、出厂流量等变量。对于题目未明确给出物理单位的字段，本文不额外推断其量纲，仅保留原始数据形式。

原始字段 T/W PUMP DUTY 使用泵组编号组合表示运行状态，例如“1&3”、“2&4”等。由于泵编号本身不具有数值大小意义，而运行泵数量能够更直接反映系统运行负荷，因此本文将该字段转换为运行泵数量特征。

5.3 缺失值分析

原始数据中部分变量存在不同程度缺失，且缺失模式具有明显差异。统计结果表明，R/W FLOW、R/W NTU、FILT. NTU、C/W WELL LEVEL 和 T/W FLOW 等核心运行变量缺失率均低于 1%，具有较好的连续性和完整性；而 ALUM、CL2、R/W PH 等工艺控制变量缺失率约为 30%，F/RIDE 缺失率达到 75.68%。18ML LEVEL 与 18ML FLOW 在整个观测期间均为空值，不具备分析价值，因此在后续建模中予以剔除。此外，2026 年 2 月 NTU 整月缺失，对应题目要求预测的目标数据，因此保留为空，不参与插补。

进一步分析发现，部分变量的缺失并非随机漏测，而是来源于若干月份未进行记录。例如 ALUM、CL2、R/W PH 和 T/W PUMP DUTY 等变量均存在连续月份整体缺失的现象。因此，简单删除缺失样本将导致样本规模显著下降，而直接删除缺失变量又可能损失重要工艺信息。

为评估不同缺失值处理策略对影响因素识别结果的影响，后续问题一分别构建“删除缺失特征”和“删除缺失样本”两种分析方案，并通过多种统计与机器学习方法进行交叉验证，以提高影响因素筛选结果的稳健性。

5.4 异常值检测

为评估数据质量并识别可能存在的异常观测，本文对连续数值变量进行异常值检测。考虑到水质监测数据具有明显的时间连续性和局部稳定性，采用基于中位数绝对偏差（Median Absolute Deviation, MAD）的 Hampel 方法进行局部离群点识别。

对于时间序列 x_t ，在以 t 为中心的局部窗口内计算中位数 m_t 与中位数绝对偏差 MAD_t 。若满足

$$|x_t - m_t| > 5 \times 1.4826 \times MAD_t,$$

则将该观测标记为统计离群点。本文采用长度为 13 个观测点的中心窗口，对应约 24 小时的局部时间范围。

检测结果表明，原水浊度、滤后水浊度、处理后水浊度以及流量等变量均存在一定数量的局部异常观测。这些异常点既可能来源于传感器噪声或记录误差，也可能反映真实的水质波动事件。考虑到题目后续需要分析水质风险及异常变化过程，本文仅对离群点进行标记而不删除原始观测值，以保留实际运行过程中的关键信息。

6 问题一：主要影响因素筛选与出厂水浊度预测模型

6.1 候选影响因素选取

由于原始数据中部分变量存在不同程度缺失，直接采用单一数据处理策略可能导致变量重要性结果受到样本规模或特征完整性的影响。为提高结论的稳健性，本文分别构建两套分析数据集进行交叉验证。

方案 A 采用“删除缺失特征”的策略，即保留全部目标值有效样本，删除存在缺失记录的输入变量；方案 B 采用“删除缺失样本”的策略，即保留全部非空输入变量，但删除任一输入特征存在缺失的观测记录。两种方案分别代表“保留样本规模优先”和“保留变量信息优先”的两种建模思路。

在两套数据集上，分别采用 Pearson 相关系数、Spearman 相关系数、Random Forest 特征重要性、XGBoost 特征重要性以及 SHAP 解释分析对变量影响程度进行评估，各方法得到的重要变量排序结果见附录 A。为降低单一分析方法带来的偏差，本文统计各变量在两种缺失值处理方案下、六类分析方法前三重要变量中的出现频次，并以此衡量

变量重要性的稳定性。出现频次越高，说明该变量在不同数据处理策略和分析框架下均表现出较强影响力。统计结果如2所示。

表 2 主要影响因素综合筛选结果

变量	出现次数
FILT.NTU	8
RIVER LEVEL	6
R/W FLOW	4
T/W FLOW	4
CLR	3
ALUM	2
R/W NTU	2
T/W PUMP DUTY	1

除统计分析结果外，本文结合供水工艺机理对变量进行补充筛选。考虑到 CL2 和 F/RIDE 分别反映水力停留状态、消毒工艺状态及水质监测指标，故将其纳入最终影响因素集合。最终确定的问题一关键影响因素集合为：最终确定的关键影响因素包括：*FILT.NTU*, *CLR*, *R/W FLOW*, *T/W FLOW*, *RIVER LEVEL*, *R/W NTU*, *ALUM*, *CL2*, *T/W*。后续影响程度分析、作用方向分析以及预测模型构建均基于上述变量集合展开。

6.2 影响程度与作用方向分析

为进一步解释各影响因素对出厂水浊度（NTU）的作用机制，本文结合相关性分析与 SHAP 解释模型，对关键变量的影响程度及作用方向进行研究。




图 2 方案 B 下 Pearson 与 Spearman 相关系数热力图




图 3 方案 B 下两种模型的 SHAP 解释结果

图 2给出了方案 B 下 Pearson 相关系数与 Spearman 相关系数热力图。Pearson 相关系数主要反映变量间的线性关系，而 Spearman 相关系数能够反映变量间的单调关系。由图可见，FILT.NTU、RIVER LEVEL、R/W NTU 等变量与出厂水浊度均表现出较明显的正相关关系，其中 FILT.NTU 与 NTU 的相关性最为显著，表明滤后水浊度是影响最终出厂水质的重要前置指标。

同时本文采用 SHAP 方法对随机森林模型进行解释，结果如图 3所示。SHAP 结果表明，FILT.NTU 和 RIVER LEVEL 具有最大的平均贡献度，是影响出厂水浊度的核心因素。其中，当 FILT.NTU 取值较高时，其对应 SHAP 值主要分布于正区间，说明滤后水浊度升高将显著提高出厂水浊度预测值；同样，较高的 RIVER LEVEL 也倾向于产生正向贡献，表明较高水位状态下系统更容易出现浊度升高现象。

T/W FLOW 和 R/W FLOW 的重要性排名同样较高，说明进出厂流量变化会通过改变系统运行负荷和水力停留条件影响最终水质。对于 ALUM 变量，高取值样本对应的 SHAP 值多数位于负区间，表明适当增加混凝剂投加量有助于降低出厂水浊度，这与实际水处理工艺机理一致。

综合相关性分析、特征重要性分析及 SHAP 解释结果，FILT.NTU、RIVER LEVEL、R/W FLOW 和 T/W FLOW 在多种评价方法下均保持较高的重要性，是影响出厂水浊度变化的核心因素。SHAP 分析进一步表明，FILT.NTU、RIVER LEVEL 以及进出厂流量总体与 NTU 呈正向关系，而 ALUM 表现出负向调节作用，说明增加混凝剂投加量有助于降低出厂水浊度。上述结论与实际水处理工艺机理相符，为后续建立预测模型提供了依据。

6.3 出厂水浊度预测模型

首先采用 Pearson 相关系数和 Spearman 相关系数分析各变量与出厂水浊度之间的线性和单调关系。对于变量 x_i 与目标变量 y ，Pearson 相关系数为

$$r_{x_i,y} = \frac{\sum_{t=1}^n (x_{i,t} - \bar{x}_i)(y_t - \bar{y})}{\sqrt{\sum_{t=1}^n (x_{i,t} - \bar{x}_i)^2} \sqrt{\sum_{t=1}^n (y_t - \bar{y})^2}} \quad (1)$$

进一步地，对不同滞后阶数下的变量与目标变量计算相关性，以识别潜在时滞影响。

6.4 模型性能评价与预测结果

为刻画输入变量与出厂水浊度之间的非线性关系，本文建立 XGBoost 回归模型。模型输入为当前变量及其滞后特征，输出为出厂水浊度 y_t 。模型预测形式为

$$\hat{y}_t = F(X_t, X_{t-1}, \dots, X_{t-12}). \quad (2)$$

表 3 不同模型对出厂水 NTU 的预测性能对比

模型	$RMSE$	MAE	R^2
多元线性回归			
随机森林			
XGBoost			
GRU			

表 4 2026 年 2 月指定日期出厂水 NTU 预测结果

日期	时间	预测值	真实值	绝对误差
2026-02-01				
2026-02-10				
2026-02-20				

7 问题二：滤后水浊度的时滞动态模型

7.1 滤后水浊度影响机制分析

滤后水浊度 $FILT.NTU$ 是衡量混凝、沉淀和过滤效果的重要指标。原水浊度反映进入处理系统的颗粒负荷，原水 pH 会影响混凝剂效果，矾投加量是调控混凝反应的关键变量，原水流量则影响反应时间和过滤负荷。上述变量对滤后水浊度的影响并非即时发生，而是存在不同程度的时间滞后。

7.2 动态时滞模型建立

设 z_t 表示 t 时刻滤后水浊度， $x_{i,t-\tau_i}$ 表示第 i 个输入变量在滞后 τ_i 后对滤后水浊度产生影响，则动态模型可表示为

$$z_t = f(x_{1,t-\tau_1}, x_{2,t-\tau_2}, \dots, x_{m,t-\tau_m}) + \varepsilon_t. \quad (3)$$

其中， $\tau_i \in \{0, 1, \dots, 12\}$ ，对应 0–24 小时滞后。

7.3 最优时滞参数识别

本文结合滞后相关性、网格搜索和模型特征重要性确定各变量的最优时滞。对于每个变量，在候选滞后阶数集合中选择使模型预测误差最小或特征贡献最大的滞后阶数。

表 5 主要输入变量的最优时滞参数

输入变量	最优滞后阶数	滞后时间/h	作用方向
R/W NTU			
R/W PH			
ALUM			
$F/RIDE$			
R/W FLOW			

7.4 模型验证

表 6 $FILT.NTU$ 动态模型预测性能

模型	$RMSE$	MAE	R^2
ARX 基准模型			
滞后随机森林模型			
Lag-XGBoost 模型			

8 问题三：基于水力停留时间与 GRU 的出厂水浊度多步预测模型

由于 18ML LEVEL 和 18ML FLOW 在本数据集中完全缺失，本文不将其纳入模型，而采用 C/W WELL LEVEL 与 T/W FLOW 构造近似水力停留时间特征。清水池具有调蓄和混合作用，当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用 L_t 表示清水池水位，用 Q_t 表示出厂水流量，则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (4)$$

其中 ϵ 为防止分母为零的极小常数。

8.1 水力停留时间特征构造

清水池具有调蓄和混合作用，当前出厂水浊度通常受到过去一段时间滤后水和清水池状态的共同影响。若用 L_t 表示清水池水位，用 Q_t 表示出厂水流量，则近似水力停留时间特征定义为

$$HRT_t = \frac{L_t}{Q_t + \epsilon}, \quad (5)$$

其中 ϵ 为防止分母为零的极小常数。

8.2 多步预测问题定义

由于采样间隔为 2 小时，未来 1-12 小时预测可转化为未来 1-6 步预测。设 $h = 1, 2, \dots, 6$ ，则多步预测目标为

$$\hat{y}_{t+h} = g(y_{t-k:t}, z_{t-k:t}, X_{t-k:t}, HRT_{t-k:t}), \quad (6)$$

其中 k 表示历史窗口长度。

8.3 GRU 模型结构

GRU 通过更新门和重置门刻画历史序列信息，其基本结构为

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r), \quad (7)$$

$$u_t = \sigma(W_u x_t + U_u h_{t-1} + b_u), \quad (8)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h), \quad (9)$$

$$h_t = (1 - u_t) \odot h_{t-1} + u_t \odot \tilde{h}_t. \quad (10)$$

8.4 多步预测性能评价

表 7 不同预测步长下模型预测性能

预测步长	对应时间	$RMSE$	MAE	R^2
1 step	2 h			
2 steps	4 h			
3 steps	6 h			
4 steps	8 h			
5 steps	10 h			
6 steps	12 h			

8.5 指定日期 7:00 至 19:00 预测结果

表 8 2026 年 2 月指定日期 7:00 至 19:00 出厂水 NTU 预测结果

日期	时间	2h 预测	4h 预测	6h 预测	12h 预测
2026-02-01	07:00				
2026-02-01	09:00				
2026-02-01	11:00				
2026-02-01	13:00				
2026-02-01	15:00				
2026-02-01	17:00				
2026-02-01	19:00				

8.6 输入变量敏感性分析

为分析原水水质突变和矾投加调整对未来出厂水浊度预测结果的影响，本文设计情景扰动实验。设原始输入为 X_t ，扰动后输入为 X'_t ，则相对敏感度定义为

$$S_i = \frac{\Delta \hat{y} / \hat{y}}{\Delta x_i / x_i}. \quad (11)$$

9 问题四：水质风险评价模型

9.1 风险评价指标构建

以出厂水浊度 y_t 为核心指标，根据生活饮用水浊度限值 $NTU \leq 1$ 定义超标幅度

$$E_t = \max(0, y_t - 1). \tag{12}$$

同时定义浊度波动指标

$$V_t = |y_t - y_{t-1}|. \tag{13}$$

设 D_t 表示连续异常持续时间，则综合风险指数为

$$R_t = \alpha E_t + \beta D_t + \gamma V_t, \tag{14}$$

其中 α, β, γ 为权重，满足 $\alpha + \beta + \gamma = 1$ 。

9.2 风险等级划分

表 9 水质风险等级划分标准

风险等级	判定依据	含义
安全	未超标且波动较小	水质稳定达标
低风险	接近阈值或短时轻微波动	需要关注
中风险	短时超标或波动明显	需要采取调控措施
高风险	持续超标或严重异常	需要立即干预

9.3 2026 年近三个月风险评价结果

表 10 2026 年 1-3 月各风险等级天数占比

风险等级	天数	占比
安全		
低风险		
中风险		
高风险		

表 11 2026 年 3 月每日风险分类结果

日期	日均 NTU	日最大 NTU	连续超标时长/h	风险等级
2026-03-01				
2026-03-02				
此处补充 3 月完整日期结果				

10 模型评价与敏感性分析

本节从预测精度、解释性、稳定性和实际应用价值四个方面评价模型。预测精度采用 $RMSE$ 、 MAE 和 R^2 衡量；解释性通过 SHAP 重要性、时滞参数和风险指标构成体现；稳定性通过不同月份、不同预测步长和输入扰动情景下的模型表现进行检验。

11 模型优缺点

11.1 模型优点

- (1) 充分考虑水处理过程的时间滞后特征，避免静态建模的局限；
- (2) 将 XGBoost、SHAP 与 GRU 结合，兼顾预测精度和可解释性；
- (3) 引入近似水力停留时间特征，使模型具有一定机理解释；
- (4) 风险评价同时考虑超标幅度、持续时间和波动程度，较单一阈值判断更合理。

11.2 模型不足

- (1) 清水池水力停留时间只能由水位和流量近似表征，可能与真实停留时间存在偏差；
- (2) 部分变量缺失率较高，可能影响完整变量模型的稳定性；
- (3) 对极端异常工况的预测能力依赖历史样本覆盖情况。

12 结论

本文围绕自来水厂水浊度预测与风险评估问题，构建了从数据预处理、影响因素筛选、时滞动态建模、多步预测到风险分级的完整建模框架。后续将在完成数据清洗和模型训练后，补充各问题的具体数值结果、预测表格和图形分析。

参考文献

- [1] 国家市场监督管理总局, 中国国家标准化管理委员会. 生活饮用水卫生标准: GB 5749-2022[S]. 北京: 中国标准出版社, 2022.
- [2] Qasim S R, Motley E M, Zhu G. Water Works Engineering: Planning, Design and Operation[M]. Upper Saddle River: Prentice Hall, 2000.
- [3] Box G E P, Jenkins G M, Reinsel G C, Ljung G M. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: Wiley, 2015.
- [4] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [5] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [6] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C]. Advances in Neural Information Processing Systems, 2017, 30: 4765-4774.
- [7] Cho K, van Merriënboer B, Gulcehre C, Bahdanau D, Bougares F, Schwenk H, Bengio Y. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]. Proceedings of EMNLP, 2014: 1724-1734.
- [8] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [9] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M/OL]. 3rd ed. Melbourne: OTexts, 2021. <https://otexts.com/fpp3/>, 访问时间: 2026 年 6 月 12 日.
- [10] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge: MIT Press, 2016.

13 附录

表 12 不同缺失值处理方案下各方法的重要变量排序结果

方案	最佳模型	最佳 RMSE	RF 重 要性前 三	XGB 重要性 前三	RF SHAP 前三	XGB SHAP 前三	Pearson 前三	Spearman 前三
A	XGBoost	0.3864	FILT. NTU, CLR, RIVER LEVEL	CLR, FILT. NTU, R/W FLOW	FILT. NTU, T/W FLOW, RIVER LEVEL	FILT. NTU, T/W FLOW, RIVER LEVEL	FILT. NTU, CLR, R/W FLOW	R/W FLOW, T/W FLOW, FILT. NTU
B	Random Forest	0.0921	FILT. NTU, RIVER LEVEL, R/W NTU	FILT. NTU, T/W PUMP DUTY, ALUM	RIVER LEVEL, FILT. NTU, T/W FLOW	FILT. NTU, RIVER LEVEL, ALUM	FILT. NTU, RIVER LEVEL, R/W NTU	RIVER LEVEL, ALUM, R/W CLR